

教师信息

- 姓名: 王祎乐
- 研究方向: 自然语言处理
- 办公室: 致真楼711
- 邮箱: wangyile@szu.edu.cn

- 1.消息同步在企业微信“数据挖掘课程群”
- 2.课件会发布在“荔园畅课”
- 3.支持在实验课时间去机房做实验、做作业、学习等，
不做强制要求


- 1.平时成绩60%：包括四次实验作业
- 2.期末成绩40%：大作业（1-2人一组，最后4-5次课上台汇报+纸质版论文），可选题包括：
 - 1) 使用大模型完成复杂数据挖掘任务
 - 2) 部署OpenClaw(龙虾)完成复杂事务处理
 - 3) 自己已完成的数据挖掘相关比赛等



绪论

2026/3/12

相关学科



模式识别

计算机视觉



数据挖掘



机器学习

语音识别




统计学习







自然语言处理



机器学习 vs. 人类学习









A vertical line on the left side of the page contains five circular nodes. The top node is black with the number '1' in white. The other four nodes are light gray with black outlines and contain the numbers '2', '3', '4', and '5' respectively. To the right of each node is a rectangular box. The box for node 1 is black with white text. The boxes for nodes 2 through 5 are light gray with black outlines and black text. The boxes are aligned horizontally with their respective nodes.

1	某知名连锁餐饮企业的困惑
2	从餐饮服务到数据挖掘
3	数据挖掘的基本任务
4	数据挖掘建模过程
5	数据挖掘竞赛

T餐饮简介

- 国内某餐饮连锁有限公司（以下简称T餐饮）成立于1998年，主要经营粤菜，兼顾湘菜、川菜、中餐等综合菜系。至今已经发展成为在国内具有一定知名度、美誉度，多品牌、立体化的大型餐饮连锁企业。
- 属下员工1000多人，拥有16家直营分店，经营总面积近13000平方米，年营业额近亿元。
- 其旗下各分店均坐落在繁华市区主干道，雅致的装潢，配之以精致的饰品、灯具、器物，出品精美，服务规范。



- 近年来餐饮行业面临较为复杂的市场环境，与其他行业一样餐饮企业都遇到了原材料成本升高、人力成本升高、房租成本升高等问题，这也使得整个行业的利润率急剧下降。人力成本和房租成本的上升是必然趋势，如何在保持产品质量同时提高企业效率，成为了T餐饮急需面对的问题。从2000年开始，T餐饮通过加强信息化管理来提高效率，目前已上线的管理系统包括：

1. 客户关系管理系统
2. 前厅管理系统
3. 后厨管理系统
4. 财务管理系统
5. 物资管理系统

T餐饮的困惑

- 通过以上信息化的建设，T餐饮已经积累了大量的历史数据，有没有一种方法可帮助企业从这些数据中洞察商机，提取价值？在同质化的市场竞争中，找到一些市场以前并不存在的“捡漏”和“补缺”？

1	某知名连锁餐饮企业的困惑
2	从餐饮服务到数据挖掘
3	数据挖掘的基本任务
4	数据挖掘建模过程
5	数据挖掘竞赛

餐饮如何盈利.....


- 企业经营最大的目的就是盈利，而餐饮业企业盈利的核心就是其菜品和顾客，也就是其提供的产品和服务对象。企业经营者每天都在想推出什么样的菜系和种类会吸引更多的顾客，究竟各种顾客各自的喜好是什么，在不同的时段是不是有不同的菜品畅销，当把几种不同的菜品组合在一起推出时是不是能够得到更好的效果，未来一段时间菜品原材应该采购多少.....

T餐饮服务之经验.....

- T餐饮在经营过程中，通过分析历史数据，总结出一些行之有效的经验：
 1. 在点餐过程中，由有经验的服务员根据**顾客特点**进行菜品推荐，一方面可提高菜品的销量，另外一方面可减少客户点餐的时间和频率，提高用户体验；
 2. 根据菜品历史销售情况，综合考虑节假日、气候和竞争对手等影响因素，对菜品销量进行**预测**，以便餐饮企业提前准备原材料；
 3. 定期对菜品销售情况进行统计，**分类统计**出好评菜和差评菜，为促销活动和新品推出提供支持；
 4. 根据就餐频率和金额对顾客的就餐行为进行评分，**筛选出优质客户**，定期回访和送去关怀。

从餐饮服务到数据挖掘

- 以上经验从数据中获得有关产品和客户的特点以及能够产生价值的规律更多依赖于管理人员的个人经验。
- 如果有一套工具或系统，能够从业务数据中自动或半自动地发现相关的知识和解决方案，这将极大地提高企业的决策水平和竞争能力。
- 这种从数据中“淘金”，从大量数据（包括文本）中挖掘出隐含的、未知的、对决策有潜在价值的关系、模式和趋势，并用这些知识和规则建立用于决策支持的模型，提供预测性决策支持的方法、工具和过程，就是**数据挖掘**。



分析能力的八个等级



分析能力的八个等级



常规报表 STANDARD REPORTS

回答: 发生了什么? 什么时候发生的?

示例: 月度或季度财务报表

我们都见过报表, 它们一般是定期生成, 用来回答在某个特定的领域发生了什么。从某种程度上来说它们是有用的, 但无法用于制定长期决策。



即席查询 AD HOC REPORTS

回答: 有多少数量? 发生了多少次? 在哪里?

示例: 一周内各天各种门诊的病人数量报告。

即席查询的最大好处是, 让你不断提出问题并寻找答案。



多维分析 OLAP

回答: 问题到底出在哪里? 我该如何寻找答案?

示例: 对各种手机类型的用户进行排序, 探查他们的呼叫行为。

通过多维分析(OLAP)的钻取功能, 可以让您有初步的发现。钻取功能如同层层剥笋, 发现问题所在。



警报 ALERTS

回答: 我什么时候该有所反应? 现在该做什么?

示例: 当销售额落后于目标时, 销售总监将收到警报。

警报可以让您知道什么时候出了问题, 并当问题再次出现时及时告知您。警报可以通过电子邮件、RSS订阅、评分卡或仪表盘上的红色信号灯来展示。

分析能力的八个等级



统计分析 STATISTICAL ANALYSIS

回答：为什么会出现这种情况？我错失了什么机会？

示例：银行可以弄清楚为什么重新申请房贷的客户在增多。

这时您已经可以进行一些复杂的分析，比如频次分析模型或回归分析等等。统计分析是在历史数据中进行统计并总结规律。



预报 FORECASTING

回答：如果持续这种发展趋势，未来会怎么样？还需要多少？什么时候需要？

示例：零售商可以预计特定商品未来一段时间在各个门店的需求量。

预报可以说是最热门的分析应用之一，各行各业都用得到。特别对于供应商来说，能够准确预报需求，就可以让他们合理安排库存，既不会缺货，也不会积压。



预测型建模 PREDICTIVE MODELING

回答：接下来会发生什么？它对业务的影响程度如何？

示例：酒店和娱乐行业可以预测哪些VIP客户会对特定度假产品有兴趣。

如果您拥有上千万的客户，并希望展开一次市场营销活动，那么哪些人会是最可能响应的客户呢？如何划分出这些客户？哪些客户会流失？预测型建模能够给出解答。




优化 OPTIMIZATION

回答：如何把事情做得更好？对于一个复杂问题来说，那种决策是最优的？


示例：在给定了业务上的优先级、资源调配的约束条件以及可用技术的情况下，请您来给出IT平台优化的最佳方案，以满足每个用户的需求。

优化带来创新，它同时考虑到资源与需求，帮助您找到实现目标的最佳方式。

数据分析能力的演进



分析和执行能力远跟不上信息的增长



1	某知名连锁餐饮企业的困惑
2	从餐饮服务到数据挖掘
3	数据挖掘的基本任务
4	数据挖掘建模过程
5	数据挖掘竞赛



数据挖掘的基本任务

- 数据挖掘的**基本任务**包括利用分类与预测、聚类分析、关联规则、时序模式、偏差检测、智能推荐等方法，帮助企业提取数据中蕴含的商业价值，提高企业的竞争力。
- 餐饮企业数据挖掘的基本任务：
 - 从餐饮企业采集各类菜品销量、成本单价、会员消费、促销活动等内部数据，以及天气、节假日、竞争对手以及周边商业氛围等外部数据；
 - 利用数据分析手段，实现菜品智能推荐、促销效果分析、客户价值分析、新店选点优化、热销/滞销菜品分析和销量趋势预测
 - 将这些分析结果推送给餐饮企业管理者及有关服务人员，为餐饮企业降低运营成本，增加盈利能力，实现精准营销，策划促销活动等提供智能服务支持。

数据挖掘的基本任务

分类与预测


有目标的对事物进行分类预测，如：客户流失预测、偷窃电用户识别等。



数据挖掘的基本任务

➤ 聚类分析


聚类分析是根据数据本身结构特征对数据点进行分类的方法。实质是按照彼此距离的远近将数据分为若干个类别，以使得类别内数据的“差异性”尽可能小(即“同质性”尽可能大)，类别间“差异性”尽可能大。



数据挖掘的基本任务

➤ 推荐

推荐系统是利用电子商务网站向客户提供商品信息和建议，模拟销售人员帮助客户完成购买过程。个性化推荐是根据用户的兴趣特点和购买行为，向用户推荐用户感兴趣的信息和商品。




数据挖掘的基本任务

➤ 时间序列分析

基于事物发展的延续性和随机性预测事物未来的发展，如：销售量预测、天气预测等。



时间



Basic Sales

CPFR > Sales Forecast > Basic Sales

Brand name: lotto Product Type: Total

Transactions period: [] ~ []

Date: By Week Analysis Method: Exponential Smoothing Search

Basic Sales Forecast Model

Basic Sales Forecast Model

250,000,000
200,000,000
150,000,000
100,000,000
50,000,000
0

200807 200808 200809 200810 200811 200812 200901 200902 200903 200904 200905 200906 200907 200908 200909 200910

Basic Forecast value real value

Copyright©2009 by JEINE CAC All right reserved

Year	Week	Real Value	Basic Forecast value	Error rate(%)
2009(P)	6	125,772,500	125,135,726	0.506
2009(P)	7	117,801,600	131,013,926	-11.216
2009(P)	8	118,455,600	120,832,211	-2.006
2009(F)	9		159,092,141	
2009(F)	10		179,591,587	


1	某知名连锁餐饮企业的困惑
2	从餐饮服务到数据挖掘
3	数据挖掘的基本任务
4	数据挖掘建模过程
5	数据挖掘竞赛

数据挖掘建模过程



数据挖掘建模过程

● 餐饮行业数据挖掘建模过程：



第1步：定义挖掘目标

- 针对具体的数据挖掘应用需求，首先要明确本次的挖掘目标是什么？系统完成后能达到什么样的效果？因此我们必须分析应用领域，包括应用中的各种知识和应用目标，了解相关领域的有关情况，熟悉背景知识，弄清用户需求。要想充分发挥数据挖掘的价值，必须要对目标有一个清晰明确的定义，即决定到底想干什么。

第1步：定义挖掘目标

- 针对餐饮行业的数据挖掘应用，可定义如下挖掘目标：
 1. 实现动态菜品智能推荐，帮助顾客快速发现自己感兴趣的菜品，同时确保推荐给顾客的菜品也是餐饮企业所期望的，实现餐饮消费者和餐饮企业的双赢；
 2. 对餐饮客户进行细分，了解不同客户的贡献度和消费特征，分析哪些客户是最有价值的，哪些是最需要关注的，对不同价值的客户采取不同的营销策略，将有限的资源投放到最有价值的客户身上，实现精准化营销；
 3. 基于菜品历史销售情况，综合考虑节假日、气候和竞争对手等影响因素，对菜品销量进行趋势预测，方便餐饮企业准备原材料；
 4. 基于餐饮大数据，优化新店选址，并对新店位置的潜在顾客口味偏好进行分析，以便及时进行菜式调整。

数据挖掘建模过程

第2步：数据取样

- 在明确了需要进行数据挖掘的目标后，接下来就需要从业务系统中抽取出一个与挖掘目标相关的样本数据子集。**抽取数据的标准**，一是相关性，二是可靠性，三是有效性，而不是动用全部企业数据。通过数据样本的精选，不仅能减少数据处理量，节省系统资源，而且使我们想要寻找的规律性更加突显出来。
- 进行数据取样，一定要严把质量关。因为数据挖掘是要探索企业运作的内在规律性，原始数据有误，就很难从中探索规律性。若真的从中还探索出来了什么“规律性”，再依此去指导工作，则很可能造成误导。若从正在运行的系统中进行数据取样，更要注意数据的完整性和有效性。

第2步：数据取样

● 数据抽样方法：

1. 随机抽样：在采用随机抽样方式时，数据集中的每一组观测值都有相同的被抽样的概率。
2. 等距抽样：如按 5%的比例对一个有100 组观测值的数据集进行等距抽样，则有： $100 / 5 = 20$ ，等距抽样方式是取第20、40、60、80 和第100 五组观测值。
3. 分层抽样：在这种抽样操作时，首先将样本总体分成若干个子集。在每个层次中的观测值都具有相同的被选用的概率，但对不同的层次可设定不同的概率。这样的抽样结果通常具有更好的代表性，进而使模型具有更好的拟合精度。
4. 从起始顺序抽样：这种抽样方式是从输入数据集的起始处开始抽样。抽样的数量可以给定一个百分比，或者直接给定选取观测值的组数。
5. 分类抽样：在前述几种抽样方式中，并不考虑抽取样本的具体取值。分类抽样则依据某种属性的取值来选择数据子集。如按客户名称分类、按地址区域分类等。分类抽样的选取方式就是前面所述的几种方式，只是抽样以类为单位。

第2步：数据取样

- 餐饮建模数据取样：

1. 餐饮企业信息：名称、位置、规模、联系方式；部门、人员、角色等；
2. 餐饮客户信息：姓名、联系方式、消费时间、消费金额等；
3. 餐饮企业菜品信息：菜品名称、菜品单价、菜品成本、所属部门等；
4. 菜品销量数据：菜品名称、销售日期、销售金额、销售份数；
5. 原材料供应商资料及商品数据：供应商姓名、联系方式、商品名称；客户评价信息；
6. 促销活动数据：促销日期、促销内容、促销描述；
7. 外部数据，如天气、节假日、竞争对手以及周边商业氛围等数据。

第3步：数据探索

- 数据取样，多少是带着人们对如何实现数据挖掘目的的先验认识进行操作的。当我们拿到了一个样本数据集后，它是否达到我们原来设想的要求；其中有没有什么明显的规律和趋势；有没有出现从未设想过的数据状态；属性之间有什么相关性；它们可区分成怎样一些类别.....
- 对所抽取的样本数据进行探索、审核和必要的加工处理，是保证最终的挖掘模型的质量所必需的。可以说，挖掘模型的质量不会超过抽取样本的质量。数据探索和预处理的目的是为了保证样本数据的质量，从而为保证模型质量打下基础。
- 数据探索主要包括：异常值分析、缺失值分析、相关分析、周期性分析等。


第3步：数据预处理

- 由于采样数据中常常包含许多含有噪声、不完整、甚至不一致的数据，对数据挖掘所涉及的数据对象必须进行预处理。那么如何对数据进行预处理以改善数据质量，并最终达到完善最终的数据挖掘结果的目的呢？
- 针对采集的餐饮数据，数据预处理主要包括：数据筛选、数据变量转换、缺失值处理、坏数据处理、数据标准化、主成分分析、属性选择、数据规约等。

数据挖掘建模过程

第4步：挖掘建模

- 样本抽取完成并经预处理后，接下来要考虑的问题是：本次建模属于数据挖掘应用中的哪类问题（分类、聚类、关联规则、时序模式或是智能推荐），选用哪种算法进行模型构建？
- 针对餐饮行业的数据挖掘应用，挖掘建模主要包括基于关联规则算法的动态菜品智能推荐、基于聚类算法的餐饮客户价值分析、基于分类与预测算法的菜品销量预测、基于整体优化的新店选址。
- 以菜品销量预测为例，模型构建是对菜品历史销量，综合考虑节假日、气候和竞争对手等采样数据轨迹的概括，它反映的是采样数据内部结构的一般特征，并与该采样数据的具体结构基本吻合。模型的具体化就是菜品销量预测公式，公式可以产生与观察值有相似结构的输出，这就是预测值。



第5步：模型评价

- 模型评价的目的之一就是从这些模型中自动找出一个最好的模型出来，另外就是要根据业务对模型进行解释和应用。
- 对分类与预测模型和聚类分析模型的评价方法是不同的。
- 不管黑猫、白猫，抓到老鼠就是好猫。

1	某知名连锁餐饮企业的困惑
2	从餐饮服务到数据挖掘
3	数据挖掘的基本任务
4	数据挖掘建模过程
5	数据挖掘竞赛

数据挖掘竞赛平台


名称	链接	说明
Kaggle	www.kaggle.com	全球最大的DM比赛平台，鼓励开源
DrivenData	www.drivendata.org	较为成熟的平台，以图像和视频比赛为主
天池	tianchi.aliyun.com	阿里旗下，知名度最高的中文DM平台
DataCastle	www.pkbigdata.com	四川电科大，对选手比较友好
DataFountain	www.datafountain.cn	CCF背景，每年定期举办CCF数据挖掘比赛
Biendata	biendata.com	清华学术背景，比赛偏优化和学术
科赛	www.kesci.com	国内最类似kaggle的平台
...	...	...

为什么参加数据竞赛？

1. 数据挖掘比赛是非常考验动手/思考/debug/实践能力的；
2. 数据挖掘比赛，都是有具体的业务场景的，和工业界完美结合；
3. 参加比赛能够证明自己，寻求好的求职/升学机会；
4. 能够认识志同道合的朋友；

总结：技术能力++；机会++；人脉圈++

为什么参加数据竞赛?



ML/DM/DL理论

```
from sklearn.feature_selection import RFE
from sklearn.linear_model import LinearRegression

boston = load_boston()
X = boston["data"]
Y = boston["target"]
names = boston["feature_names"]

#use linear regression as the model
lr = LinearRegression()
#rank all features, i.e continue the elimination
rfe = RFE(lr, n_features_to_select=1)
rfe.fit(X,Y)
```

具体问题实践

理论只是告诉我们有这个东西，是什么原理的；但方法怎么用，用到什么 场景是需要我们更加掌握的。需要理论+实践！

常见的赛题类型

- 常见的赛题类型可分为三类：
 - 分类问题：用户是否违约；图像分类；
 - 回归问题：用户贷款金额；PM2.5回归预测；
 - 时序问题：商铺销量预测；打车流量预测；
- 赛题根据数据又可分为：
 - 结构化数据挖掘：
 - 非结构化数据挖掘：
- 赛题根据业务场景又可分为：
 - 风控类型问题；
 - CTR类问题
 - 推荐类问题
 - 欺诈检测类问题

$$f(\text{features})=y$$



Python数据分析工具

2026/3/12

Python数据分析工具

- Python本身的数据分析功能不强，需要安装一些第三方扩展库来增强它的能力。本课程用到的库有Numpy、Scipy、Matplotlib、Pandas、Scikit-Learn、PyTorch等，下面将对这些库的安装和使用进行简单的介绍。

扩展库	简介
Numpy	提供数组支持，以及相应的高效的处理函数
Scipy	提供矩阵支持，以及矩阵相关的数值计算模块
Matplotlib	强大的数据可视化工具、作图库
Pandas	强大、灵活的数据分析和探索工具
StatsModels	统计建模和计量经济学，包括描述统计、统计模型估计和推断
Scikit-Learn	支持回归、分类、聚类等的强大的机器学习库

Numpy

Numpy是Python的一种开源科学计算扩展，旨在存储和处理大型矩阵。它的设计是为了提高Python在数值计算方面的性能，支持大量的维度数组与矩阵运算。Numpy还包含了大量的数学函数库，如线性代数`linalg`、傅里叶变换`fft`和随机数生成`random`等，特别适合于需要进行严格数字处理的场合，如机器学习和图像处理领域。


Numpy的核心类型是多维数组对象`ndarray`，它具有以下特点：

- 所有元素的数据类型必须相同。
- 下标从0开始。
- 数组的形状可以通过`shape`属性获取。
- `size`属性表示数组的元素总数，即形状的乘积。
- `dtype`属性描述数组中元素的类型。
- `itemsize`属性表示数组的每个元素的大小（以字节为单位）

Numpy简单例子

```
In [1]: import numpy as np
```

```
In [5]: #创建一维数组
arr1 = np.array([1, 2, 3])
print("创建一维数组:")
print(arr1)
#创建二维数组
print("创建二维数组:")
arr2 = np.array([[1, 2, 3], [1, 2, 3]])
print(arr2)
#查看数组维度
print("查看数组维度:")
print(arr2.ndim)
#查看元素数量
print("查看元素数量:")
print(arr2.size)
#查看数组形状
print("查看数组形状:")
print(arr2.shape)
#查看数据对象类型
print("查看数据对象类型:")
print(type(arr2))
#创建指定数值范围的数组
print("创建指定数值范围的数组:")
print(np.arange(1, 12, 2))
#生成随机数
print("生成随机数:")
print(np.random.rand(5))
```



```
创建一维数组:
[1 2 3]
创建二维数组:
[[1 2 3]
 [1 2 3]]
查看数组维度:
2
查看元素数量:
6
查看数组形状:
(2, 3)
查看数据对象类型:
<class 'numpy.ndarray'>
创建指定数值范围的数组:
[ 1  3  5  7  9 11]
生成随机数:
[0.44631899 0.25094616 0.76045322 0.61970387 0.45969902]
```

Numpy常用数学函数

类别	NumPy函数	Math模块函数	功能
数学常数	<code>np.e</code>	<code>math.e</code>	自然常数
数学常数	<code>np.pi</code>	<code>math.pi</code>	圆周率
舍入函数	<code>np.ceil()</code>	<code>math.ceil()</code>	进尾取整
舍入函数	<code>np.floor()</code>	<code>math.floor()</code>	去尾取整
舍入函数	<code>np.around()</code>		四舍五入到指定精度
舍入函数	<code>np rint()</code>		四舍五入到最近整数
快速转换函数	<code>np.deg2rad()</code> 、 <code>np.radians()</code>	<code>np.radians()</code>	度转弧度
快速转换函数	<code>np.rad2deg()</code> 、 <code>np.degrees()</code>	<code>math.degrees()</code>	弧度转度
幂指数对数函数	<code>np.hypot()</code>	<code>math.hypot()</code>	计算直角三角形的斜边
幂指数对数函数	<code>np.square()</code>		平方
幂指数对数函数	<code>np.sqrt()</code>	<code>math.sqrt()</code>	开平方
幂指数对数函数	<code>np.power()</code>	<code>math.pow()</code>	幂
幂指数对数函数	<code>np.exp()</code>	<code>math.exp()</code>	指数
幂指数对数函数	<code>np.log()</code> 、 <code>np.log10()</code> 、 <code>np.log2()</code>	<code>math.log()</code> 、 <code>math.log10()</code> 、 <code>math.log2()</code>	对数
三角函数	<code>np.sin()/arcsin()</code>	<code>math.sin()/asin()</code>	正弦/反正弦
三角函数	<code>np.cos()/arccos()</code>	<code>math.cos()/acos()</code>	余弦/反余弦
三角函数	<code>np.tan()/arctan()</code>	<code>math.tan()/atan()</code>	正切/反正切

Numpy常用统计函数

类别	函数	功能
查找特殊值	<code>np.max/min(a,axis=None)</code>	返回最大值/最小值
查找特殊值	<code>np.nanmax/nanmin(a, axis=None)</code>	忽略nan返回最大值/最小值
查找特殊值	<code>np.argmax/argmin(a, axis=None)</code>	返回最大值和最小值的索引号
查找特殊值	<code>np.nanargmax/nanargmin(a, axis=None)</code>	忽略nan返回最大值和最小值索引号
查找特殊值	<code>np.median(a, axis=None)</code>	返回中位数
查找特殊值	<code>np.nanmedian(a, axis=None)</code>	忽略nan返回中位数
求和差积	<code>np.ptp(a, axis=None)</code>	返回元素最大值与最小值的差
求和差积	<code>np.sum(a, axis=None)</code>	按指定轴求和
求和差积	<code>np.nansum(a, axis=None)</code>	忽略nan按指定轴求和
求和差积	<code>np.cumsum(a, axis=None)</code>	按指定轴求累计和
求和差积	<code>np.nancumsum(a, axis=None)</code>	忽略nan按指定轴求累计和
求和差积	<code>np.diff(a, axis=None)</code>	按指定轴返回相邻元素的差
求和差积	<code>np.prod(a, axis=None)</code>	按指定轴求积
求和差积	<code>np.nanprod(a, axis=None)</code>	忽略nan按指定轴返回算数平均值

Scipy是Python中的科学计算库，由Travis Olliphant于2001年创建。它的目标是提供一种高级的、高效的科学计算环境，为科学家、工程师和数据分析师提供丰富的工具和函数。

Scipy提供了如下功能：

- 优化：Scipy包括了各种数学优化算法，可以用于寻找函数的最小值或最大值。
- 信号处理：Scipy提供了一系列信号处理工具，用于分析和处理信号数据。
- 统计分析：Scipy包括了各种统计分析函数，用于描述和分析数据的统计特性。
- 插值：Scipy提供了插值函数，用于估计在给定数据点之间的值。
- 线性代数：Scipy包括了线性代数工具，用于解决线性方程组和矩阵分解等问题。

Scipy简单例子

```
import scipy
```

```
from scipy.optimize import minimize
```

```
# 定义目标函数
```

```
def objective(x):  
    return x[0]**2 + x[1]**2
```

```
# 初始猜测点
```

```
x0 = [1, 1]
```


```
# 使用BFGS算法寻找最小值
```

```
result = minimize(objective, x0, method='BFGS')
```

```
# 输出最小值和最优参数
```

```
print("最小值:", result.fun)
```

```
print("最优参数:", result.x)
```



最小值: 2.311471135620994e-16

最优参数: [-1.07505143e-08 -1.07505143e-08]

Scipy常见模块

模块名	功能
scipy.cluster	向量量化
scipy.constants	数学常量
scipy.fft	快速傅里叶变换
scipy.integrate	积分
scipy.interpolate	插值
scipy.io	数据输入输出
scipy.linalg	线性代数
scipy.misc	图像处理
scipy.ndimage	N 维图像
scipy.odr	正交距离回归
scipy.optimize	优化算法
scipy.signal	信号处理
scipy.sparse	稀疏矩阵
scipy.spatial	空间数据结构和算法
scipy.special	特殊数学函数
scipy.stats	统计函数

Matplotlib

Python中最常用的绘图库之一，主要特点包括：

- 丰富的图表类型：支持各种常见的图表类型，包括折线图、散点图、柱状图、饼图、箱线图、等高线图等。
- 高度可定制性：提供了丰富的配置选项，允许自定义图表的各个方面，包括线条样式、颜色、坐标轴刻度、标签、标题等。
- 支持多种输出格式：支持将图表保存为多种格式，如图像文件（PNG、JPEG、SVG等）、PDF文档等。
- 支持交互式图表：可以与其他库（如NumPy、Pandas、Seaborn）以及IPython等交互式环境相结合，实现动态和交互式的数据可视化。


Matplotlib简单例子

```
import matplotlib.pyplot as plt


#Plot a line graph
plt.plot([5, 15], label='Rice')
plt.plot([3, 6], label='Oil')
plt.plot([8.0010, 14.2], label='Wheat')
plt.plot([1.95412, 6.98547, 5.41411, 5.99, 7.9999], label='Coffee')

# Add labels and title
plt.title("Interactive Plot")
plt.xlabel("X-axis")
plt.ylabel("Y-axis")


plt.legend()
plt.show()
```



Interactive Plot



Anatomy of a figure



Pandas

Pandas 是 Python 数据分析的必备高级工具之一，从 Numpy 和 Matplotlib 的基础上构建而来，享有数据分析“三剑客之一”的盛名（NumPy、Matplotlib、Pandas）。

Pandas的特点包括：

- 提供了一个简单、高效、带有默认标签（也可以自定义标签）的 DataFrame 对象来便于用户使用；
- 能够快速得从不同格式的文件中加载数据（比如 Excel、CSV、SQL文件），然后将其转换为可处理的对象；
- 能够按数据的行、列标签进行分组，并对分组后的对象执行聚合和转换操作；
- 能够很方便地实现数据归一化操作和缺失值处理；
- 能够很方便地对 DataFrame 的数据列进行增加、修改或者删除的操作；
- 能够处理不同格式的数据集，比如矩阵数据、异构数据表、时间序列等；
- 提供了多种处理数据集的方式，比如构建子集、切片、过滤、分组以及重新排序等。

Pandas导入数据


模块名	功能
read_csv	从CSV文件导入数据
read_table	从限定分隔符的文本文件导入数据
read_excel	从Excel文件导入数据
read_sql	从SQL表/库导入数据
read_json	从JSON格式的字符串导入数据
read_html	解析URL、字符串或者HTML文件，抽取其中的tables表格
read_clipboard	从你的粘贴板获取内容，并传给read_table()
DataFrame	从字典对象导入数据，Key是列名，Value是数据

Pandas简单例子

```
import pandas as pd

temp_dict = {'name': ['xiaohong', 'xiaozhang'], 'age': [30, 23], 'tel': [10086, 10010]}
t1 = pd.DataFrame(temp_dict)
print(t1)

temp_dict1 = [{'name': 'xiaohong', 'age': 23, 'tel': 10086}, {'name': 'xiaogang', 'age': 12}, {'name': 'xiaozhang', 'tel': 10010}]
t2 = pd.DataFrame(temp_dict1)
print(t2)
```



	name	age	tel
0	xiaohong	30	10086
1	xiaozhang	23	10010

	name	age	tel
0	xiaohong	23.0	10086.0
1	xiaogang	12.0	NaN
2	xiaozhang	NaN	10010.0

StatsModels

Statsmodels是一个功能强大、灵活可扩展的Python库，用于进行统计建模和数据分析。它提供了一系列丰富的统计模型和方法，可以帮助研究人员和数据科学家在Python环境中进行高级统计分析。

StatsModels的特点包括：

- 模型多样性：提供多种统计模型，包括线性模型、广义线性模型（GLM）、健壮线性模型、线性混合效应模型、方差分析（ANOVA）等。
- 时间序列分析：支持时间序列分析方法和模型，包括ARIMA（自回归积分滑动平均模型）、季节性分解和状态空间模型。
- 结果诊断和模型评估：提供详细的结果统计和诊断工具，以评估模型的适用性和假设的有效性，如残差分析、Q-Q图、F检验等。
- 统计测试：支持广泛的统计测试，用于比较群组、检验变量间的相关性、进行假设检验等。

StatsModels简单例子（简单线性回归）

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm


# 创建数据
x = np.random.rand(100)
y = 2 * x + np.random.normal(0, 0.1, 100)

# 添加截距
X = sm.add_constant(x)

# 使用OLS进行线性回归
model = sm.OLS(y, X)
results = model.fit()


# 输出结果
print(results.summary())

# 绘制拟合线
plt.scatter(x, y)
plt.plot(x, results.params[0] + results.params[1] * x, color='red')
plt.show()
```



OLS Regression Results						
Dep. Variable:	y	R-squared:	0.970			
Model:	OLS	Adj. R-squared:	0.970			
Method:	Least Squares	F-statistic:	3178.			
Date:	Thu, 07 Mar 2024	Prob (F-statistic):	1.70e-76			
Time:	20:37:27	Log-Likelihood:	88.043			
No. Observations:	100	AIC:	-172.1			
Df Residuals:	98	BIC:	-166.9			
Df Model:	1					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
const	-0.0202	0.020	-1.002	0.319	-0.060	0.020
x1	2.0285	0.036	56.374	0.000	1.957	2.100
Omnibus:	0.177	Durbin-Watson:	1.840			
Prob(Omnibus):	0.915	Jarque-Bera (JB):	0.033			
Skew:	-0.043	Prob(JB):	0.983			
Kurtosis:	3.025	Cond. No.	4.44			

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.



Scikit-Learn是一个开源的机器学习库，用于Python编程语言，广泛用于各种数据挖掘和数据分析任务。


主要特点：

- 广泛的功能范围：提供了许多机器学习算法的实现，包括分类、回归、聚类及降维等。
- 高效性能：Scikit-Learn背后使用了高效的算法实现，部分算法使用了Cython来提高性能。
- 与其他科学计算库的兼容性：与NumPy和SciPy等其他Python科学计算库集成良好，可以轻松处理任何数值和科学计算任务。
- 开源和商业友好的BSD许可：可以在商业产品中免费使用Scikit-Learn而不必担心版权问题。

Scikit-Learn常用数据集


大小	sklearn数据集	调用方法	适用算法
小	波士顿房价数据集	<code>load_boston()</code>	回归
小	鸢尾花数据集	<code>load_iris()</code>	分类
小	糖尿病数据集	<code>load_diabetes()</code>	回归
小	手写数字数据集	<code>load_digits()</code>	分类
大	Olivetti脸部图像数据集	<code>fetch_olivetti_faces()</code>	降维
大	新闻分类数据集	<code>fetch_20newsgroups()</code>	分类
大	带标签的人脸数据集	<code>fetch_lfw_people()</code>	分类、降维
大	路透社新闻语料数据集	<code>fetch_revl()</code>	分类

Scikit-Learn常用函数



Scikit-Learn常用函数

scikit-learn algorithm cheat-sheet



Scikit-Learn简单例子（鸢尾花）

```
from sklearn import neighbors, datasets, preprocessing
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score

# 1-1) data Load
iris = datasets.load_iris()
X, y = iris.data[:, :2], iris.target
# 1-2) train/test split
X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=33)
# 1-3) data preprocess
scaler = preprocessing.StandardScaler().fit(X_train)
X_train = scaler.transform(X_train)
X_test = scaler.transform(X_test)
# 1-4) setup Model
knn = neighbors.KNeighborsClassifier(n_neighbors=5)
# 1-5) Model training
knn.fit(X_train, y_train)
# 1-6) predict the test set using trained-Model
y_pred = knn.predict(X_test)
# 1-7) Score the Model
scoreOut = accuracy_score(y_test, y_pred):
print("预测准确率为：", scoreOut)
```



预测准确率为： 0.631578947368421

PyTorch是一个广泛用于机器学习和深度学习的编程框架。它由Meta的人工智能研究团队开发和维护，是一个开源的软件包，可以帮助开发者构建各种深度学习模型。

主要特点：

- 易于使用和学习：PyTorch采用了类似于Python的语法，使得它容易上手和学习。它还提供了丰富的文档和教程，使得开发者可以快速掌握它的基本使用方法。
- 动态计算图：PyTorch使用动态计算图，这意味着计算图是根据代码在运行时动态生成的，而不是在编译时静态生成的。这使得它更加灵活和易于调试。
- 高效的GPU加速：PyTorch可以在GPU上高效地运行，这使得它能够处理大规模的数据集和模型。
- 强大的自动微分：PyTorch内置了自动微分功能，这使得开发者可以轻松地计算模型的导数，从而加快了模型的训练和优化过程。
- 大量的预训练模型：PyTorch拥有大量的预训练模型，包括ImageNet、COCO、CIFAR等，这些模型可以用于各种计算机视觉和自然语言处理任务，使得开发者能够快速构建模型并取得优秀的效果。

PyTorch简单例子


```
# 导入Pytorch
import torch

# 构造一个未初始化的5 * 3的矩阵
x = torch.empty(5, 3) # 5行3列的未初始化Tensor
print("构造一个未初始化的5 * 3的矩阵:")
print(x)

# 构造一个随机初始化的矩阵
x = torch.rand(5, 3) # 5行3列的随机初始化Tensor, 都在0-1之间
print("构造一个随机初始化的矩阵:")
print(x)

# 构造一个全部为0, 类型为long的矩阵
x = torch.zeros(5, 3, dtype=torch.long)
print("构造一个全部为0, 类型为long的矩阵:")
print(x)

# 从数据中直接构造tensor
x = torch.tensor([5.5, 3]) # tensor([5.5000, 3.0000])
print("从数据中直接构造tensor:")
print(x)
```



构造一个未初始化的5 * 3的矩阵:

```
tensor([[ -3.2478e+32,  1.8609e-42,  0.0000e+00],
        [ 0.0000e+00,  0.0000e+00,  0.0000e+00],
        [ 0.0000e+00,  0.0000e+00,  0.0000e+00],
        [ 0.0000e+00,  0.0000e+00,  0.0000e+00],
        [ 0.0000e+00,  0.0000e+00,  0.0000e+00]])
```

构造一个随机初始化的矩阵:

```
tensor([[0.0770, 0.2749, 0.9322],
        [0.9486, 0.8560, 0.9130],
        [0.3016, 0.8560, 0.4612],
        [0.0310, 0.5828, 0.2307],
        [0.7034, 0.2653, 0.6277]])
```

构造一个全部为0, 类型为long的矩阵:

```
tensor([[0, 0, 0],
        [0, 0, 0],
        [0, 0, 0],
        [0, 0, 0],
        [0, 0, 0]])
```

从数据中直接构造tensor:

```
tensor([5.5000, 3.0000])
```

Thank You!